

Deep Learning-Based Automated Extraction of Component Regions for Semiconductor Package Defect Detection



Seungtaek Lim¹, Youngjin Park², Wonyong Choi³ and Keejun Han^{1*}

¹School of Computer Engineering, Hansung University, 116, Samseongyo-ro 16-gil, Seoul, Korea


²R&D Center, DeepSeers, 21, Bakbum-ro 31gil, Seoul, Korea

³R&D Center, Genesem, 24, Songdogwahak-ro 84beon-gil, Incheon, Korea



Introduction

최근 반도체 산업에서 인공지능(AI) 기술의 발전과 함께 고품질 반도체 생산의 중요성이 점차 부각되고 있다. 특히, 반도체 산업에서 고급의 패키징 기술은 고속 처리와 소형화, 성능 향상을 위해 핵심적인 역할을 한다. 이러한 기술들은 여러 칩을 효율적으로 결합하고, 더 작은 공간에서 더 많은 기능을 제공할 수 있는 기술로, 고급 반도체 제품의 생산에 필수적이다. 이와 같은 첨단 패키징 기술을 채택한 반도체 제조 공정에서 결합 검출은 매우 중요한 역할을 하며, 특히 반도체 비전 검사 과정에서는 검사 관심 영역(ROI, Region of Interest) 설정이 필수적이다. ROI는 결함이 발생할 수 있는 패키지 구성 요소들의 영역을 정의하는 것으로, 이를 정확히 설정하는 것이 결합 검출의 성능을 좌우한다.



기존의 Rule-base 기반의 결합 검출 시스템에서는 패키지의 구조나 형태에 따라 직접적으로 데이터를 입력하고 ROI를 설정해야 하는 번거로움이 존재한다. 이 과정은 시간이 많이 소요되고, 전문 지식을 갖춘 사용자에 의존해야 하므로 오류 발생 가능성도 높다. 특히 복잡한 구조와 다양한 결합 유형으로 인해 정확한 ROI 설정이 어려워지며, 수동적 방법의 한계가 드러나고 있다.

Objective

Deep Learnig 기반 모델을 이용한 자동화된 관심 영역(ROI) 생성 및 정확도 검증

딥러닝 모델을 활용한 자동화된 검사 시스템을 구축하고 딥러닝 모델이 불량 검출 및 패키징 구성 영역 추출에서 얼마나 효율적이고 정확한 성능을 보이는지 평가한다.

이미지 증강 및 전처리 기법을 통한 성능 향상


모델이 불필요한 데이터를 학습 하지 않고 패키지의 주요 부분을 학습하여 크기가 작은 패키지의 구성 요소들을 탐지할 때 정확도를 높이고 학습 데이터의 증강을 통해 이미지를 다양한 색상, 채도 및 밝기 조건에서 훈련시켜 모델이 다양한 조명과 환경에서 정확성을 유지할 수 있도록 만든다 .

Methods

딥러닝 기반의 객체 탐지 모델을 사용하여 QFN(Quad Flat No-lead) 및 BGA(Ball Grid Array) 반도체 패키지에서 ROI(Region of Interest)를 자동으로 추출하는 성능을 평가하였다. 실험은 두 가지 주요 단계로 구성되며, 각 단계에서 데이터를 다르게 처리하여 모델 성능을 최적화한다. 첫 번째 단계에서는 YOLOv8, YOLOv9, YOLOv10, YOLOv11 등의 딥러닝 기반의 객체탐지 모델을 이용해 관심 영역(ROI) 추출하고 모델의 성능을 평가하는 것이며, 두 번째 단계는 이미지 증강 및 전처리 기법을 적용하여 학습한 뒤 개선된 성능을 확인한다 .

Model

YOLOv8, YOLOv9, YOLOv10, YOLOv11

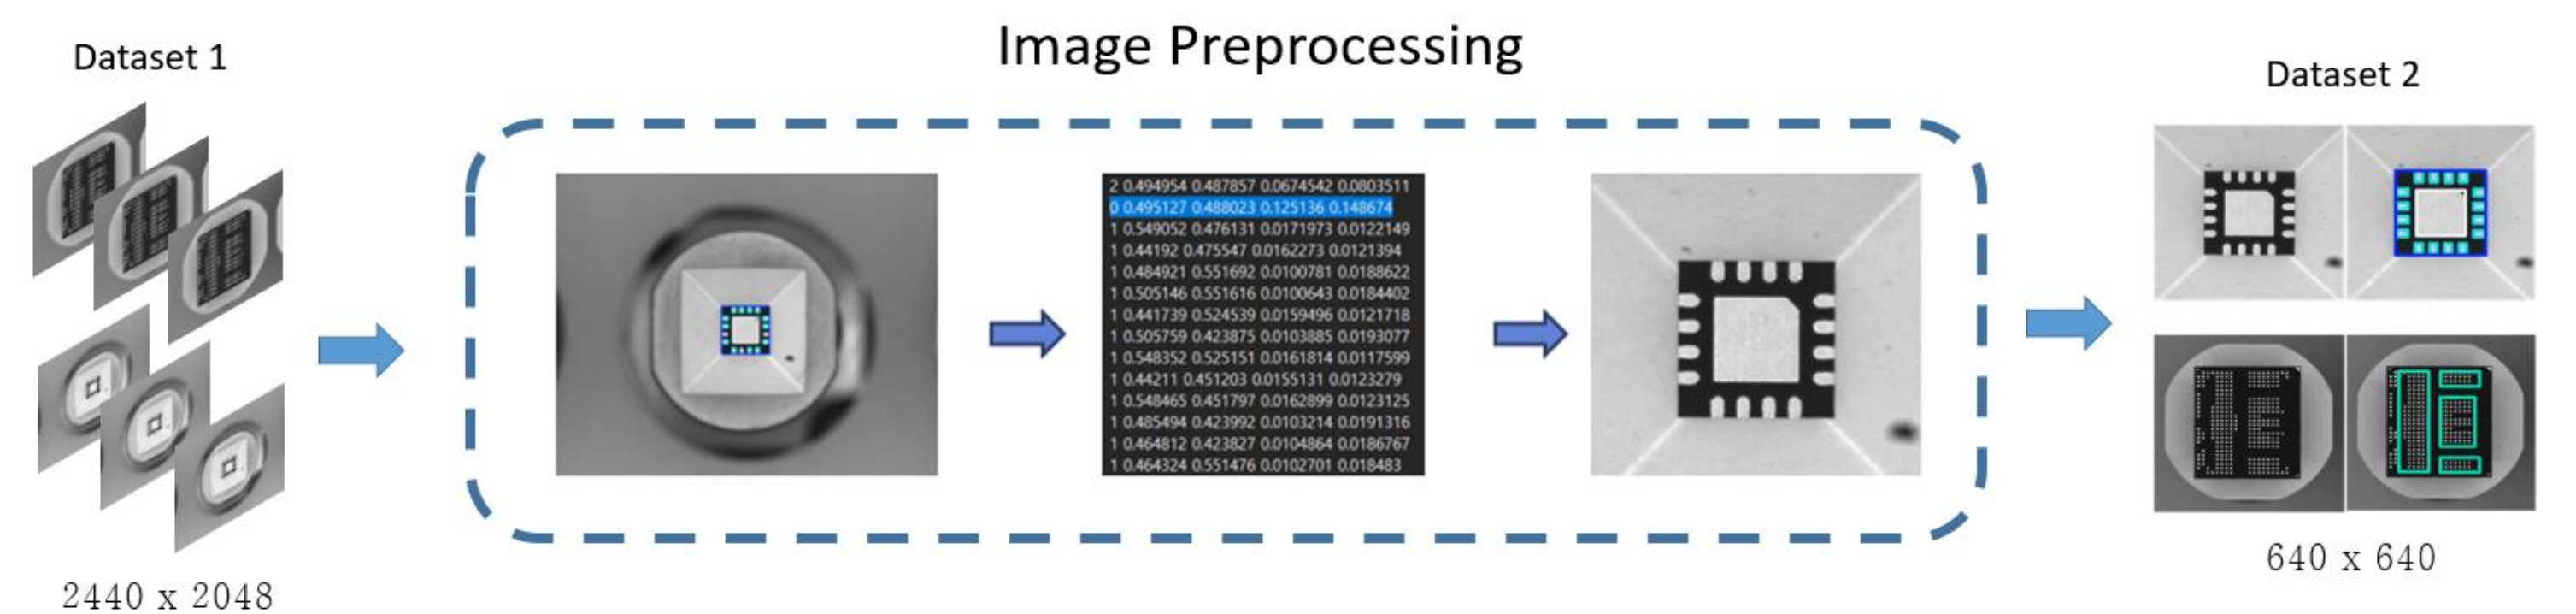


YOLO는 이미지를 N x N 그리드 셀로 나누어 각 셀이 포함하는 객체의 클래스와 존재 확률을 예측한다. 각 그리드 셀은 객체의 위치를 파악하고, IOU(Intersection Over Union) 값이 높은 불필요한 예측을 제외한다. 이후 중복된 박스를 제거하고, 가장 높은 확률을 가진 박스만 남긴다. 각 그리드 셀은 조건부 클래스 확률을 예측하고, 이를 바운딩 박스의 신뢰도와 곱해 객체의 위치와 여부를 최종적으로 예측한다. 이 방식은 빠르고 정확한 객체 탐지를 할 수 있게 해주어 .반도체 제조 공정에서의 빠르고 정확한 관심 영역 추출을 가능하게 해준다.

Dataset


Dataset 1

The datasets used in the experiment are images of QFN and BGA semiconductor packages used in actual mass production lines, and each dataset consists of regions of interest (ROI) of package components such as Package, Lead, Pad, and Ball.



Dataset 2

The preprocessed Dataset1 images are cropped and resized to the standard input size of 640 x 640 for YOLO, based on the labeled package areas, and are composed of the cropped and resized images along with their corresponding labels.



Validation Dataset

This dataset, used for validation, is composed of augmented images to verify the model's generalization ability to various brightness changes, such as light reflection, excessive exposure, and issues with the lighting system, that may occur in real-world environments.

Metrics

•Precision (정밀도) :

- ROI 추출에 있어 얼마나 정확하게 영역을 식별하고, 실제 영역을 얼마나 잘 찾아내는지 평가하기 위해 정밀도를 계산하였다. 정밀도는 모델이 검출한 영역 중 실제 구성요소의 영역이 포함된 비율을 나타내며, TP는 진양성(True Positive), FP는 허위양성(False Positive)을 의미한다.

$$\text{Precision} = \frac{TP}{TP + FP}$$

•Recall (재현율) :

- 재현율은 올바르게 예측된 관측치의 비율을 전체 실제 관측치에 대해 측정합니다. 이는 False Negative (잘못된 부정 예측) 발생을 강조하며, 모델이 실제 객체를 놓친 비율을 나타냅니다.

$$\text{Recall} = \frac{TP}{TP + FN}$$

•mAP50, 50-95 (Mean Average Precision across IoU thresholds from 0.50, 0.50 to 0.95):

- mAP50은 IoU가 50 이상, mAP50-95는 여러 IoU 임계값 (0.50에서 0.95까지, 0.05 단위로 증가)에 걸친 평균 정밀도를 계산합니다. 이 지표는 mAP50보다 다양한 정확도 수준에서 모델의 전반적인 성능을 더 포괄적으로 평가합니다

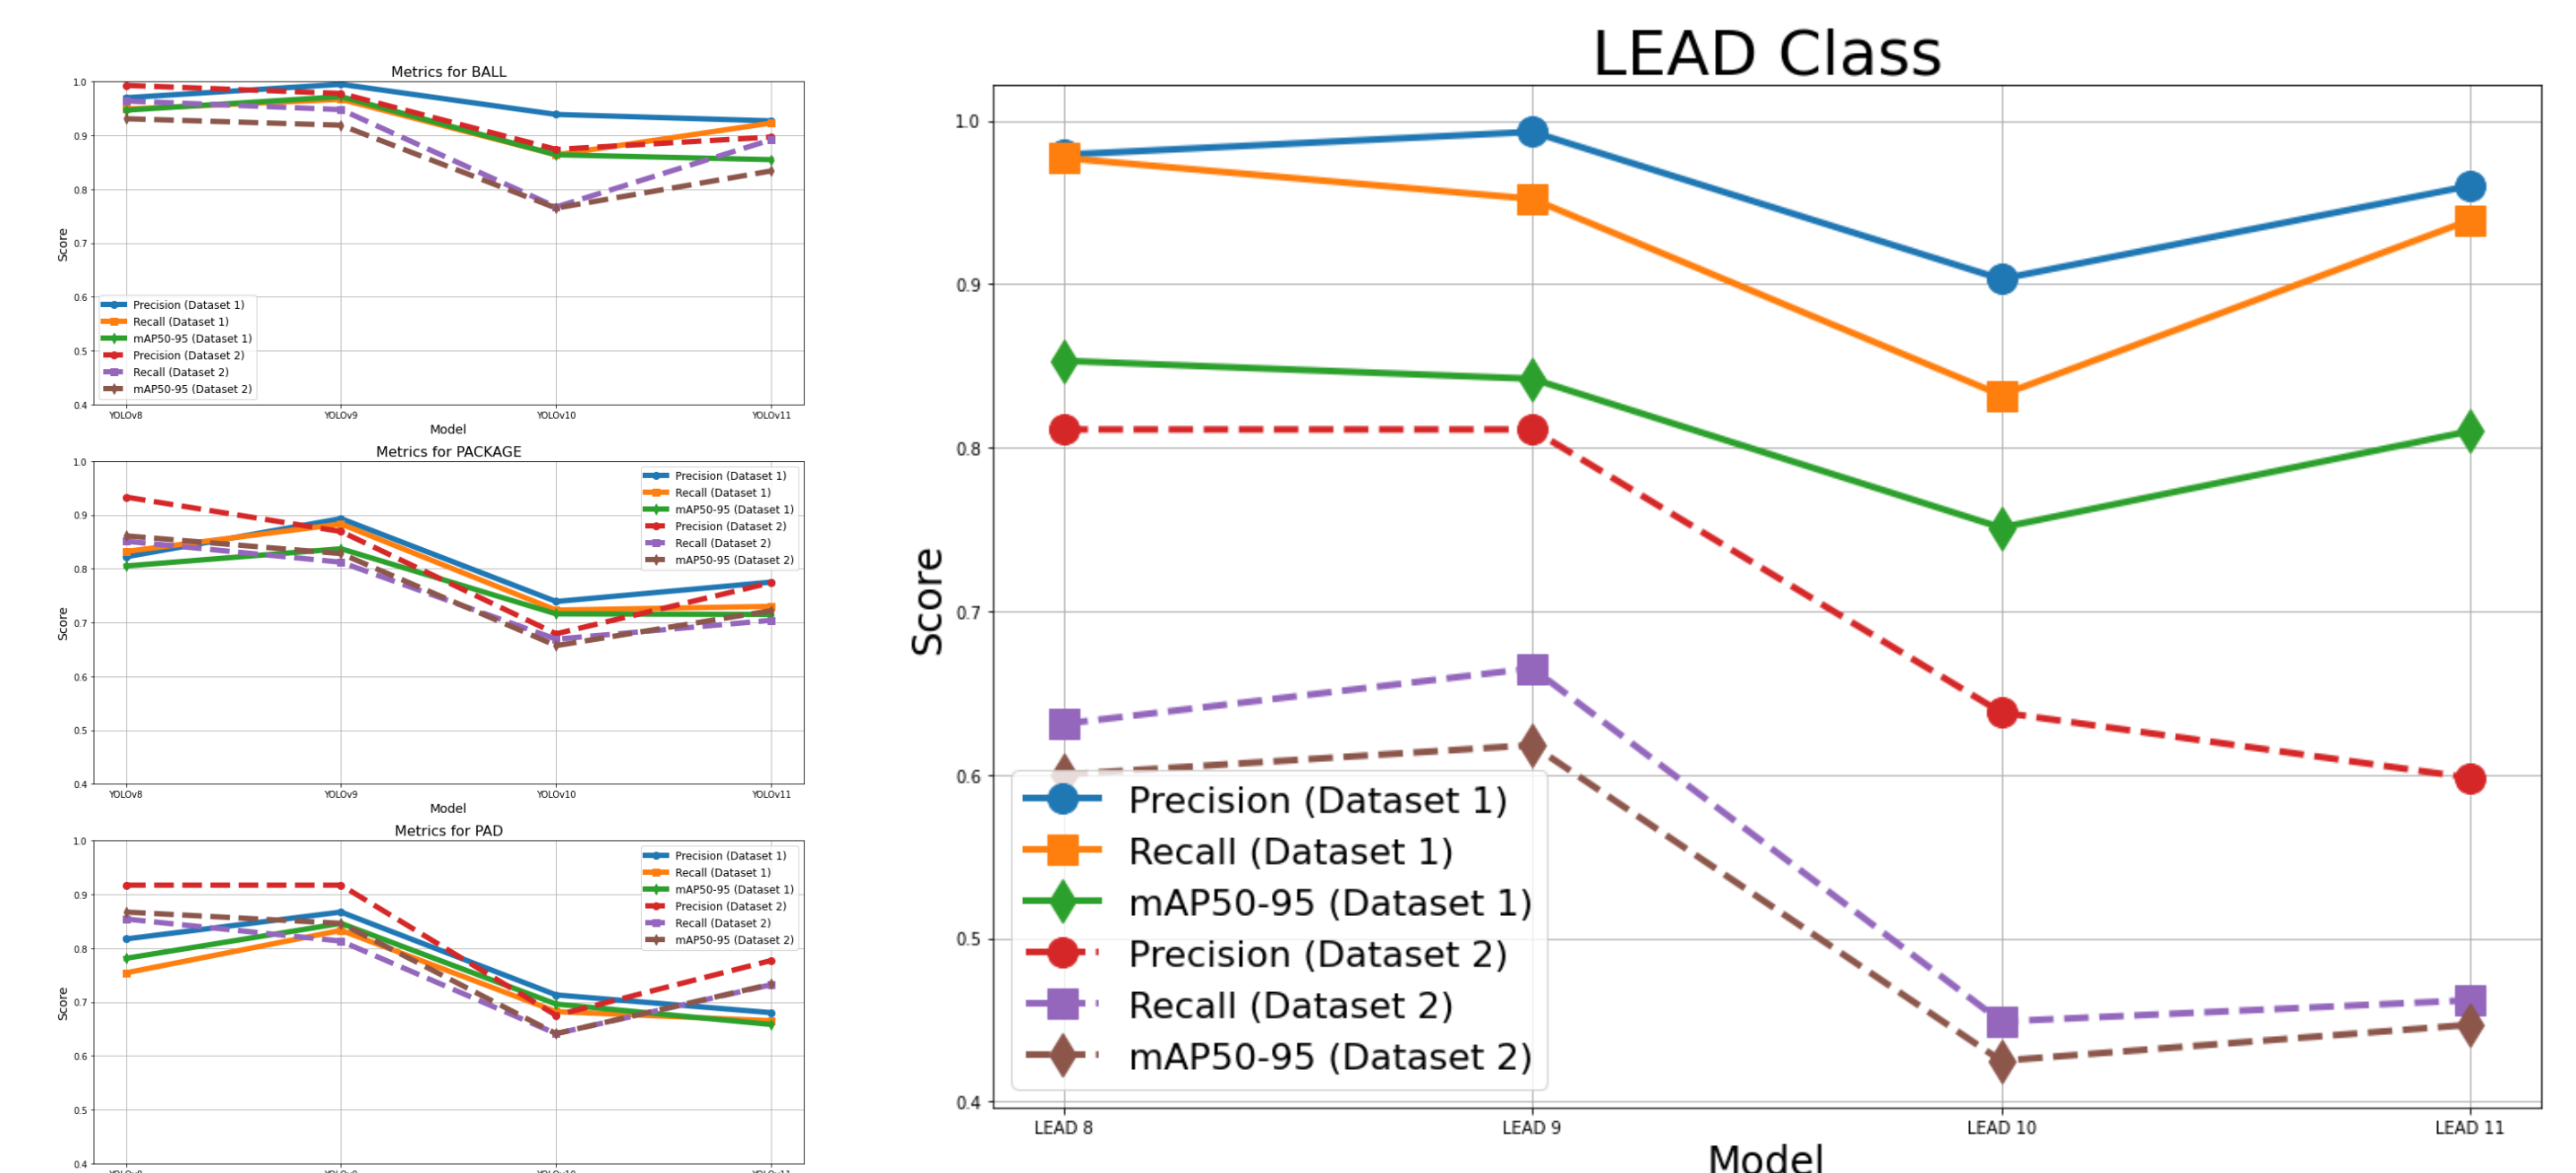
Results

딥러닝 기반 객체 탐지 모델을 사용한 패키징 구성 영역 추출에서 모델의 효율성과 정확성을 평가한 결과 Precision, Recall, mAP50, 50-95에서 각 모델 모두 준수한 수치를 기록하였고 그 중에서도 YOLOv9 모델은 Precision에서 0.922의 높은 정밀도를 보였다.

The results obtained from training using image augmentation and image preprocessing

Model	Precision	Recall	mAP50	mAP50-95
YOLOv8	0.96 (-0.007)	0.945 (+0.078)	0.95 (+0.036)	0.92 (+0.057)
YOLOv9	0.966 (+0.044)	0.941 (+0.138)	0.949 (+0.091)	0.925 (+0.112)
YOLOv10	0.913 (+0.061)	0.861 (+0.127)	0.885 (+0.089)	0.859 (+0.105)
YOLOv11	0.933 (+0.086)	0.919 (+0.152)	0.922 (+0.113)	0.895 (+0.127)

실험 결과를 보면, 전체적으로 모델들의 성능이 단계별로 개선되었으며, 특히 YOLOv9 모델에서 성능 향상이 두드러졌다. 특히 YOLOv11은 이미지 및 전처리 기법을 사용한 이후 mAP 50-95의 값이 0.127 올라 눈에 띄는 향상이 있음을 확인할 수 있었다.



그래프를 통해 확인할 수 있듯이, YOLO 모델들은 반도체 패키지 내에서 비교적 작은 크기를 가진 LEAD 클래스 탐지에서 큰 향상을 보였다. LEAD 클래스는 모든 모델에서 mAP50과 mAP50-95 값이 향상되었으며, 특히 YOLOv10과 YOLOv11에서 두드러지게 높은 성과를 나타냈다.

결론적으로, 최신 YOLO 모델을 활용한 이미지 증강 기법과 전처리 방법은 작은 객체 탐지에 큰 성과를 거두었으며, 반도체 패키지 검사 시스템의 자동화와 효율성 향상에 중요한 기여를 했다. 향후 더 많은 데이터셋과 다양한 증강 기법을 활용한 연구가 이루어지면 성능 향상이 기대된다. 또한, 데이터셋의 한계를 고려해 다양한 반도체 패키지 유형에 대한 추가 연구와 다른 딥러닝 모델(Faster R-CNN, SSD 등)과의 비교 연구가 필요하다. 이러한 연구는 반도체 검사 시스템의 정확도와 효율성 개선에 기여할 것이다.